

졸업 프로젝트 3월 2차 격주보고서		
SNN을 활용한 고효율 추천 시스템 개발 및 최적화 연구		
2020058259 이승현 2020061676 이강혁		지도교수 김상욱 교수님
지난 2주간 진행사항	CF 필터링을 구현할 프레임 워크 선정	○
	CF 필터링을 구현할 알고리즘 선정 (neuCF, autoRec 등)	○
	SNN 활용 가능성 확인을 위한 연구/논문 조사	△
진행 내용	[1] CF 필터링을 구현할 프레임 워크 선정 - pytorch Python은 다양하고 많은 라이브러리를 제공하고, python 기반의 프레임워크 Pytorch는 강력한 딥러닝 관련 함수들을 제공합니다. SNN 연구에서 이러한 Pytorch가 자주 이용되고, 이는 아직 관련 라이브러리가 적다는 SNN의 단점을 어느정도 완화할 수 있을 것입니다. [2] CF 필터링을 구현할 알고리즘 선정 - NCF 1. NCF(Neural Collaborative filtering) 유사점: NCF와 SNN 기반 CF는 둘 다 신경망 구조로 동작하고, 사용자-아이템 정보를 모두 사용합니다. (NCF의 경우 MLP를 사용한 모델을 사용할 예정) 비교점: 다른 형식의 신경망 구조를 사용하여 같은 데이터를 사용하지만 다른 구현 방식에서 오는 차이점을 비교할 수 있다.	




Figure 2: Neural collaborative filtering framework

1) Input Layer(sparse):

Input Layer는 각각 user, item을 나타내는 feature vector로 구성됩니다. 각각의 벡터는 one-hot encoding으로 표현되어 매우 sparse한 상태입니다.

2) Embedding Layer:

Embedding layer는 sparse한 input vector를 Dense하게 바꿔주는 역할을 합니다. 일반적인 임베딩 방법과 동일하게 fully-connected layer가 사용됩니다.

3) Neural CF Layers:


임베딩이 완료된 User, Item latent vector는 거치게 되는 다층 신경망 구조로, 우선 User latent vector와 Item latent vector를 concatenate한 벡터를 시작으로 각각의 층을 거치며 인공신경망을 통해 복잡한 비선형의 데이터 관계를 학습할 수 있게 됩니다.

4) Output Layer:

마지막 Layer인 Output layer에서는 NCF layer의 hidden vector를 input으로 받아 predictive score를 예측하며, Target과의 비교를 통해 학습이 진행됩니다.

2. NCF layer에서 사용되는 알고리즘 - Fusion of GMF and MLP

저자들은 MF(matrix factorization)역시 NCF framework의 특수한 경우로 해석될 수 있음을 보여줍니다.



1) GMF

NCF 프레임워크 내에서의 MF는 Generalized Matrix Factorization(GMF) 형태로 쉽게 일반화 및 확장이 가능합니다. GMF는 기존 MF를 확장하여 보다 유연한 표현이 가능하도록 한 구조입니다.

2) MLP

MLP는 GMF에 비해 더 깊은 층의 신경망을 사용하여 비선형적이고 복잡한 사용자-아이템 상호작용을 학습할 수 있습니다. 활성화 함수는 일반적인 신경망에서 사용되는 함수 중 자유롭게 선택이 가능하며, 모델 표현력에 중요한 역할을 합니다.

3) Fusion of GMF and MLP

GMF와 MLP는 각각 독립적인 임베딩 행렬을 사용하므로, 서로 다른 차원의 임베딩을 가질 수 있으며 개별적으로 학습됩니다. 최종 score는 MLP와 GMF의 output을 concatenate하여 사용합니다.

MF는 여전히 추천 시스템에서 널리 사용되며, 이는 사용자-아이템 간의 선형적인 관계를 효과적으로 포착할 수 있기 때문입니다. 반면, MLP는 복잡한 비선형 관계를 학습하는 데 강점을 가집니다.

2. autoRec

- Auto Encoder (동일한 입, 출력 구조를 사용해 압축된 latent representation을 학습할 수 있는 비지도 학습 모델)를 추천시스템에 적용한 모델입니다.

- Auto Encoder의 장점을 그대로 이어받아 Representation과 Complexity 측면에서 뛰어난 모습을 보여주고, 복잡한 non-linear latent representation을 학습할 수 있습니다.

- item과 user 중 하나에 대한 임베딩만을 진행합니다.

3. Wide and Deep

- Wide & deep은 Wide part와 Deep part로 나누어져 있으며, 각각 Memorization과 Generalization을 담당하고 있습니다.

- Memorization(-> Linear 모델)은 기존의 특성들을 사용하여 새로운 특성을 만들어 학습하는 것을 의미합니다. 주어진 데이터로부터 Frequent pattern을 찾아냅니다.

- Generalization(-> Embedding based 모델)은 Memorization과 반대로, 새로운 특성 조합에 대한 일반화된 예측을 가능하게 하는 방법입니다. 추천의 다양성을 증가시키며, 비주류 아이템을 거의 추천하지 않는 Long-tail problem을 완화시켜 줍니다.

- Wide & deep 모델의 Wide는 Memorization, Deep은 Generalization 역할입니다.
- Wide & deep의 가장 큰 의의는 Memorization과 Generalization을 동시에 수행할 수 있다는 점 입니다. Frequent pattern이면서, 다양한 추천 결과를 제공할 수 있습니다.

>> NCF를 선정하게된 이유

첫째, item과 user 정보를 동시에 사용합니다. SNN을 활용한 추천 시스템에서도 item과 user 정보를 동시에 사용할 것이기 때문에 비교하는 데에 적합하다고 생각하였습니다.

둘째, 다른 모델들이 기존의 알고리즘의 변형 내지 활용인 것에 비해 NCF는 basic한 모델이므로, SNN을 활용한 추천 시스템과 알고리즘을 비교하는 데에 가장 적합할 것이라고 생각하였습니다.

[3] SNN 활용 가능성 확인을 위한 연구/논문 조사

<주요 목표>

- (1) SNN의 구조를 추천시스템에 적용할 수 있는지
- (2) SNN을 추천시스템에 적용하는 것이 현실적으로 의미가 있는지

SNN은 이론적으로 에너지 효율적이지만, 추천시스템의 경우 항상 입력이 존재하면 그 장점이 줄어들 수 있습니다. SNN을 적용하는 것이 낮은 전력으로 높은 성능을 내는 것이 목표인데 이 장점을 click stream을 연속된 temporal spike로 만들다던지 SNN이 특정 타이밍에만 반응하게 만들다던지 어떻게 설계하여 살릴 수 있는지가 쟁점이 될 것 같습니다.

SNN의 활용을 위한 다양한 알고리즘이 연구되면서, 점진적으로, SNN의 장점을 유지하면서도 기존의 전통적인 딥러닝 모델들과 거의 비슷한 성능을 보여가고 있습니다. 이러한 이유로 SNN을 추천시스템에 적용하였을 때 유의미한 결과가 나올 것이라 생각합니다.

SNN 학습의 어려움

SNN는 생물학적으로 타당한 정보 처리 구조를 제공하지만, 학습 측면에서는 여전히 여러 도전 과제를 안고 있습니다. 대표적으로, 스파이킹 뉴런의 전달 함수는 non-differentiable하기 때문에, 전통적인 딥러닝에서 사용되는 역전파(backpropagation)를 직접적으로 적용하기 어렵습니다.

SNN 지도학습

>> NCF와의 성능 비교를 위해 지도학습 방식을 사용하고자 합니다.

최근에는 SNN에서도 지도 학습(supervised learning)을 가능하게 하기 위한 다양한 대체 알고리즘들이 활발히 연구되고 있습니다. 이는 스파이크 기반 출력과 목표 출력 사이의 오차를 최소화하려는 시도이며, 전통적인 역전파의 한계를 극복하기 위한 여러 기법들이 제안되었습니다.

- SpikeProp: 역전파를 스파이크 시간 정보에 적용한 초기 방식
- ReSuMe (Remote Supervised Method): 목표 스파이크 패턴과 실제 스파이크 패턴을 직접 비교
- Chronotron: 정해진 시간에 정확히 발화하도록 학습
- SPAN (Spike Pattern Association Neuron): 패턴 전체를 연결해 학습하는 구조

이러한 알고리즘들은 SNN에서도 정확한 목표 제어 및 학습 가능성을 보여주며, SNN의 실용적인 성능 향상 가능성을 넓히고 있습니다.

1) Xiangnan He, Lizi Liao, Hanwang Zhang, Liqiang Nie, Xia Hu, and Tat-Seng Chua. 2017. Neural Collaborative Filtering. In Proceedings of the 26th International Conference on World Wide Web (WWW '17). International World Wide Web Conferences Steering Committee, Republic and Canton of Geneva, CHE, 173–182.

<https://doi.org/10.1145/3038912.3052569>

2) <https://donghunkang.tistory.com/129>

진행 중 이슈	SNN 관련 논문을 찾아보니 여러 SNN 모델들이 있었으며, 비지도학습과 지도학습에 따라 여러 알고리즘 (비지도학습-STDP, 지도학습-SpikeProp, ReSuMe, Chronotron, SPAN)이 있다는 것을 확인했습니다. 여기에 관련해서 추가적인 조사가 아직 덜 이루어졌습니다.
다음 2주간 계획	1. Neural CF layer - GMF와 MLP 구현 2. SNN의 지도학습 모델 조사 및 공부 3. NCF와 SNN의 데이터 전처리 & 인코딩 차이 조사 (같은 전처리 과정을 사용할 수 있는지, 데이터 형식이 다른지)