

졸업 프로젝트 4월 1차 격주보고서		
SNN을 활용한 고효율 추천 시스템 개발 및 최적화 연구		
2020058259 이승현 2020061676 이강혁		지도교수 김상욱 교수님
지난 2주간 진행사항	Neural CF layer - GMF와 MLP 구현	X
	SNN의 지도학습 모델 조사 및 공부	O
	NCF와 SNN의 데이터 전처리 & 인코딩 차이 조사 (같은 전처리 과정을 사용할 수 있는지, 데이터 형식이 다른지)	△
진행 내용	1. 주제 방향성 기존의 SNN 기반 추천 시스템 연구들은 대부분 명시적 피드백(explicit feedback)을 중심으로 설계되어 있으며, 리뷰 기반 감성 분석 혹은 평점 기반 예측 구조를 활용하고 있습니다. SNN Recommendation system을 사용한 논문을 찾아본 결과, 총 3개의 논문을 찾아볼 수 있었습니다. 먼저, Agarwal, G., Dinkar, S.K. & Agarwal, A. "Binarized Spiking Neural Networks Optimized with Nomadic People Optimizer for Social Product Recommendation", Knowl Inf Syst 66, 933–958 (2024) 논문에서 BSNN-NPO는 이진화된 스파이킹 신경망과 Nomadic People Optimizer를 결합하여 소셜 제품 리뷰의 감성 분석을 기반으로 제품 및 상점을 추천하는 구조를 제안하였습니다. 이 모델은 제품 간 유사도와 협업 필터링을 병합하여 추천 성능을 향상시키려 하였지만, 리뷰가 존재하지 않는 상황에서는 작동이 어려우며 cold-start 문제에 취약하다는 단점이 있습니다. 두번째로, Solairaj A., Sugitha G., Kavitha G., "Enhanced Elman Spike Neural Network based Sentiment Analysis of Online Product Recommendation" Applied Soft Computing, Volume 132, 109789, ISSN 1568-4946 (2023) 논문이 있었습니다. 이 논문에서 설명하는 EESNN-SA-OPR 역시 SNN을 기반으로 리뷰 텍스트의 감성 수준을 분류하고, 이를 제품 추천에 활용했습니다. 전처리 단계에서 TRSF 필터링, DGLTPD 기반의 특징 추출 등을 통해 입력 텍스트의 품질을 높이려고 하였지만, 이 모델 또한 리뷰라는 명시적 피드백이 반드시 존재해야만 학습 및 추천이	

가능하다는 제한이 있었습니다. 개인화된 행동 시퀀스나 명시적 선호 외의 데이터는 반영되지 않았습니다.

가장 최근의 연구인 V. Shrivastava and S. Kumar, "Evaluation of Movie Recommender Systems Using Hesitant Fuzzy Logic and Deep Convolutional Spiking Neural Networks," *2024 4th International Conference on Advancement in Electronics & Communication Engineering (AECE)*, GHAZIABAD, India (2024)에서는 DCSNN 구조와 HFL 클러스터링을 결합하여 사용자 선호의 불확실성을 fuzzy membership으로 표현하고, 시계열적 행동을 SNN으로 모델링하였습니다. MovieLens 10M과 Rotten Tomatoes 데이터셋을 기반으로 정확도, 정밀도, MAE 등 다양한 성능 지표에서 기존 협업 필터링이나 행렬 분해 기반 기법보다 우수한 성능을 보였습니다. 그러나 이 논문 또한 입력으로 사용한 데이터는 사용자 평점과 장르 등의 메타데이터이며, 암시적 피드백에 해당하는 클릭, 조회, 구매 등의 데이터 정보는 포함하지 않았습니다.

즉, 현재까지 발표된 SNN 기반 추천 시스템 연구들은 공통적으로 명시적 피드백 또는 리뷰 기반 감성 정보에 의존하고 있으며, 실제 사용자의 행동 로그를 기반으로 한 암시적 피드백 기반 추천 구조는 없었습니다.

저희는 이와 같은 한계를 넘어서기 위해, 암시적 피드백데이터를 사용하는 SNN-CF 구조를 설계할 생각입니다. 클릭, 조회, 찜, 구매와 같은 행동 이벤트를 시간 축에 따라 spike로 변환하고, 이 시퀀스를 입력으로 받아 사용자-아이템 관계를 학습하는 SNN 구조를 구성함으로써, 명시적 피드백 없이도 작동 가능한 추천 시스템을 구현하는 것이 저희 목표입니다.

2. SNN의 지도학습 모델 조사 및 공부

1) SpikeProp

- 본래 backpropagation이 불가능한(미분 불가능하기 때문) SNN에 backpropagation 개념을 처음 도입한 모델입니다.

- 단일 스파이크(single spike)를 가정합니다. → 뉴런은 여러 번 spike하지 않고, 한 번만 spike합니다.
- 비선형성 분석이 가능합니다.
- spike의 시점과 시간이 기준이 되어 학습이 이루어집니다(시간에 따른 spike 값의 감소, spike 후 일정 시간동안 spike 무시 등).
- 오차 함수:

$$E = \frac{1}{2}(t_j - t_j^d)^2$$

- 가중치 업데이트

$$\Delta w_{ij} = -\eta \frac{\partial E}{\partial w_{ij}}$$

t_j : 출력 뉴런의 실제 spike 시간, t_j^d : 목표 spike 시간

-> 출력 뉴런의 spike 시점을 기반으로 오류를 계산하고, 이를 통해 가중치를 업데이트합니다.

- 참고 논문: Bohte et al., "SpikeProp: Backpropagation for networks of spiking neurons", Neurocomputing, 2002.

2) Tempotron

- 바이너리 분류를 위한 SNN 학습 모델입니다.
- spike 시간 기반으로 막전위(input spike의 합)가 임계값을 넘는지를 기준으로 분류합니다.
- 이벤트 기반 학습처럼 동작하며, 임계값보다 큰 막전위가 발생하면 spike를 발생시킵니다.
- 단순하고 직관적인 학습 규칙입니다.
- 막전위:

$$V(t) = \sum_i w_i \sum_{t_i} K(t - t_i)$$

K(t)는 시냅스 후 전위 커널 함수

- 가중치 업데이트:

$$\Delta w_i = \lambda \sum_{t_i < t_{max}} K(t_{max} - t_i)$$

t_{max} 는 최대 막전위 시간

-> 뉴런이 목표 시간 내에 spike를 발생시켰는지 여부에 따라 가중치를 조정합니다.

- 참고 논문: Gütig & Sompolinsky, "The Tempotron: a neuron that learns spike timing-based decisions", Nature Neuroscience 2006.

3) ReSuMe

- 신경과학 이론 Hebbian learning과 Spike-Timing Dependent Plasticity(STDP)를 결합시켜 만들어낸 모델입니다.
- 하나의 spike로만 학습하던 SpikeProp를 변형시켜, 여러 개의 spike를 input으로 받아 학습 가능하도록 합니다.
- 가중치 업데이트:

$$\Delta w_{ij} = \eta \left[\sum_{t_j^d} K(t_j^d - t_i) - \sum_{t_j} K(t_j - t_i) \right]$$

t_j^d : 목표 스파이크 시간, t_j : 실제 스파이크 시간

-> 원하는 출력 spike와 실제 출력 spike 사이의 차이에 따라 시냅스 가중치를 조절합니다.

- Ponulak & Kasiński, "Supervised learning in spiking neural networks with ReSuMe: sequence learning, classification, and spike shifting", Neural Computation, 2010.

4) SuperSpike

- Surrogate Gradient(대리 미분) 기법을 사용해, SNN의 backpropagation에서의 미분 불가능함을 해결한 모델입니다.
- ANN에서의 backpropagation과 유사한 학습이 가능합니다.
- spike 함수를 Sigmoid나 ReLU같은 연속 함수로 대체하여 spike 함수의 gradient의 근사값을 계산하여 사용합니다.
- ANN과 유사하기에 딥러닝 구성이 용이하며, 정확도 또한 ANN과 비슷합니다.

- 오차 함수:

$$E = \frac{1}{2} \sum_t (S(t) - \hat{S}(t))^2$$

- 가중치 업데이트:

$$\Delta w = -\eta \sum_t \delta(t) \frac{\partial S(t)}{\partial w}$$

$\delta(t)$: 오차 신호, $S(t)$: 스파이크 발생 확률

- 참고 논문: Zenke & Ganguli, "SuperSpike: Supervised learning in multilayer spiking neural networks", Neural Computation, 2018.

5) SLAYER

- 시간에 따른 SNN의 동적 특성을 고려한 Backpropagation Through Time(BPTT) 방식의 오차 전파 기법을 사용합니다.
- neuromorphic chip을 사용하지 않아도 성능이 크게 줄지 않지만, 계산량이 많습니다.

- 오차 역전파:

$$\delta_j(t) = \sum_k \delta_k(t) \frac{\partial V_k(t)}{\partial V_j(t)}$$

$V_k(t)$: 뉴런의 막전위

- 참고 논문: Shrestha & Orchard, "SLAYER: Spike layer error reassignment in time", Advances in Neural Information Processing Systems, 2018.

6) eProp

- SNN 모델들 중 가장 생물학적으로 타당한 모델입니다.
- 각 시냅스에서의 spike나 기타 이벤트의 자격(eligibility)을 추적하여 기록하는 eligibility trace variable을 사용하여 오류를 반영합니다.
- eligibility trace variable에 저장된 과거의 시냅스 정보를 현재 발생한 이벤트와 비교하여 옳다면 reinforce, 틀리다면 degrade하여 학습합니다.
- 지역 학습(eligibility trace) + global signal(오차)를 결합한 방식입니다.
- neuromorphic chip을 사용할 때 좋은 성능을 보입니다.
- 가중치 업데이트:

$$\Delta w_{ij} = \sum_t L_j(t) e_{ij}(t)$$

$L_j(t)$: global signal, $e_{ij}(t)$: eligibility trace variable

- 참고 논문: Bellec et al., "A solution to the learning dilemma for recurrent networks of spiking neurons", Nature Communications, 2020.

3. NCF와 SNN의 데이터 전처리 & 인코딩 차이 조사 (같은 전처리 과정을 사용할 수 있는지, 데이터 형식이 다른지)

NCF와 SNN-CF는 모두 사용자-아이템 간의 상호작용 정보를 입력으로 활용하지만, 두 모델의 학습 구조가 다르기 때문에 데이터의 전처리 및 인코딩 방식에도 차이가 존재합니다. 저희는 명시적 평점 데이터가 아닌 클릭 여부와 같은 암시적 피드백 데이터를 사용할 예정이며, 해당 데이터는 일반적으로 user_id, item_id, label 형태로 구성됩니다. 동일한 데이터를 바탕으로 하더라도 NCF와 SNN은 각자의 구조에 맞게 입력을 해석하고 처리하는 방식이 다릅니다.

NCF는 일반적으로 사용자와 아이템의 ID를 각각 one-hot 벡터로 표현한 뒤, 이를 임베딩 레이어를 통해 연속적인 latent vector로 변환합니다. 이후 GMF & MLP 과 같은 구조를 통해 비선형적인 예측 점수를 계산하며, sigmoid 함수를 이용하여 출력 확률을 도출합니다. 학습 과정에서는 일반적으로 BCE loss를 사용합니다.

반면 SNN에서는 입력 데이터를 spike 기반 신호로 변환하는 별도의 전처리 과정이 필요합니다. 주로 one-hot 벡터를 Poisson rate encoding 또는 time-to-first-spike 방식 등을 통해 시간 축을 가진 spike train으로 변환하여 신경망에 입력될 수 있는 형식으로 가공합니다. 이후 spiking 뉴런 모델을 통해 입력을 처리하고, 출력 뉴런의 spike 발생 여부나 누적 spike 개수를 기준으로 이진 분류를 수행합니다.

따라서 두 모델은 동일한 사용자-아이템 상호작용 데이터를 기반으로 하더라도, 모델 구조와 입력 형태의 차이로 인해 동일한 전처리 과정을 사용할 수 없습니다. NCF는 정적이고 연속적인 벡터 연산을 기반으로 작동하는 반면, SNN은 시간 축을 포함하는 이벤트 기반의 이산적인 신호 처리를 기반으로 학습이 이루어지기 때문입니다. 공정한 비교 실험을 위해서 동일한 입력 정보를 각 모델에 맞게 다른 방식으로 인코딩하여 적용할 예정입니다.

진행 중 이슈	04.08 교수님과의 미팅을 준비하고 진행하면서 3월 2차 미팅 당시 세웠던 계획에 집중하기보다, 추천 시스템에 대한 명확한 개념 정립과 이해가 선행되어야 함을 느꼈습니다. 이에 따라, 미팅 이후 수행해야 할 주요 과제로는 추천 시스템에서 사용되는 비지도 학습과 지도 학습 방식에 대한 정확한 이해를 위한 논문 조사 및 학습, 그리고 NCF 구조에 대한 명확한 파악 및 해당 모델이 추천 시스템으로서 어떻게 작동하는지에 대한 분석과, 또한 SNN을 추천 시스템에 적용한 선행 연구가 존재하는지 면밀히 조사하고, 관련 논문이 존재할 경우 그 내용을 완전히 이해한 후 차별화를 진행할 계획입니다. 이 과정에서 SNN의 전력 효율성이 주로 계산량 및 시간 단축으로부터 얼마나 영향을 받는지에 대해 수치적으로 분석하는 작업도 병행할 예정입니다. 마지막으로 Neuromorphic chip 없이도 유의미한 비교가 가능한지 판단하고, 실제로 Neuromorphic chip을 활용하여 전력 사용량을 비교한 논문이 있는지 조사한 뒤 그 사용 방식과 현실적으로 해당 칩을 확보하여 연구에 사용할 수 있는지 여부를 검토할 것입니다. 따라서 Neural CF layer - GMF와 MLP 구현을 뒤로 미뤄두고, 저희 주제 방향성에 관한 이해와 개념을 정확히 하고자 위와 같은 진행 내용을 선행하기로 마음먹고 진행하였습니다.
다음 4주간 계획	SNN 기반 추천 시스템의 구조 설계를 위한 데이터셋 설정 및 암시적 피드백 인코딩 및 입력 형태 구체화 SNN 추천 시스템 관련 논문 더 찾아보고 이해하기 전력 비교를 수행한 연구 조사 및 실험 설계 방향 정립 Neural CF layer - GMF와 MLP 구현