

졸업 프로젝트 5월 2차 격주보고서		
SNN을 활용한 고효율 추천 시스템 개발 및 최적화 연구		
2020058259 이승현 2020061676 이강혁		지도교수 김상욱 교수님
지난 2주간 진행사항	Neural CF layer - GMF와 MLP 통합 단계까지 구현 완료 및 학습을 통한 효율성 검증	X
진행 내용	기존에 작성한 GMF와 MLP 코드에 미흡한 부분이 있다고 생각되어 아래의 부분들을 중심으로 기존의 코드를 수정 및 개선하고자 합니다. 1. 정규화 및 초기화 저희 모델에서는 Embedding이나 Dense layer에 대해 별도의 가중치 정규화 또는 초기화 전략이 없습니다. 특히, MLP에서 Dropout, BatchNorm 등의 정규화 기법을 사용하지 않았습니다. 또한, 학습의 초기값을 설정하는 별도의 전략을 설정하지 않고 고정적으로 0으로 설정하였습니다. • 정규화는 과적합을 방지하며, 파라미터 크기를 조정하여 계산 시에 오류가 발생하지 않도록 합니다. • 초기화는 sigmoid와 같은 포화 함수가 학습할 시에 안정성을 보장해 줍니다. • 추천 시스템은 일반적으로 빅데이터에서는 분제가 크지 않지만, 작거나 희소한 데이터에서는 문제가 발생할 확률이 높으므로, 초기값 설정이 성능에 직접적인 영향을 줍니다. => outlier, 과적합, truncation error 등을 해결 및 예방하기 위해 정규화 과정을 추가할 계획입니다. => 초기값은 보편적으로 알려진 값 혹은 lecun_uniform과 같은 uniform 함수를 사용하여 경험적으로 찾아나가며 설정할 계획입니다.	

2. 샘플링

-> negative sampling 미포함

저희 모델에서는 positive feedback만 학습에 사용되며, negative feedback이 없습니다. 따라서 binary classification으로서의 NCF 학습이 불완전합니다.

현재 Positive Feedback(예: rating ≥ 4)만 사용하여 학습해서, Binary Classification으로서의 구분이 불완전합니다.

- 대부분의 실제 추천 시스템은 명시적 평점이 아니라 행동 여부(클릭/시청 등)이 주 feature가 되기 때문에 implicit feedback을 모델에 반영하기 위해서 negative sampling을 사용합니다.
- negative sampling은 콜드 스타트 문제(새로운 사용자와 아이템이 유입되었을 경우 과거의 상호작용 데이터가 부족해 기존의 데이터만으로는 정확한 추천을 제공하기 어려운 문제)나 희소한 데이터에서의 정확도 문제를 해결해줍니다. 또한, precision 향상에 기여합니다.

=> negative sampling 함수를 구현 혹은 관련 라이브러리를 import하여 negative feedback 과정을 추가할 계획입니다.

3. 평가 지표 (Hit Ratio@K, NDCG@K 등)

저희 모델에서는 단순 Accuracy 평가만 포함되어 있고 Top-K 추천 시스템 성능 지표를 반영하지 않습니다.

- 추천 시스템에서는 사용자로 하여금 구매하도록 하는 것이 목적이기 때문에 사용자별로 실제 관심 아이템의 관심 순위가 중요합니다. 이때 평가지표로 NDCG@K가 사용됩니다.
- Hit Ratio@K는 전체 사용자 수 대비 적중한 사용자 수를 나타내는 평가 지표로 단순 Accuracy보다 실질적인 정확도를 나타냅니다.

- 적합한 평가지표를 사용하여야 모델이 실제로 유의미한지 파악할 수 있습니다.

=> 이외에 Precision/Recall@K, Mean Average Precision@K, MAE & RMSE 등의 평가지표들 중 적합하다고 생각되는 지표를 선정하여 모델 평가에 사용할 계획입니다.

4. 하이퍼 파라미터

저희 모델에서 하이퍼 파라미터, 특히 MLP의 레이어 수와 크기가 고정되어 있어 실험 시에 유연성이 부족합니다.

- 하이퍼 파라미터는 경험적으로 적합한 값을 찾아야하기 때문에 접근성이 높은 것이 유리합니다.
- Dropout, BatchNorm 등을 쉽게 추가할 수 있어 확장에 용이합니다.

=> 하이퍼 파라미터를 외부 인자로 조정 가능하게 함으로써 실험의 유연성과 편리성을 높일 계획입니다.

5. 모델 저장/재현 불가

현재 구현에서는 학습된 모델을 저장하지 않기 때문에, 이후의 추론, 재학습 또는 결과를 분석하는데 있어 어려움을 겪습니다. 이는 실험의 재현성에 큰 제약을 줍니다.

=> 학습 반복 중 검증 성능을 기준으로 모델을 자동 저장하는 구조로 개선할 계획입니다. 이를 통해 최적 모델을 보존함으로써 실험의 확장성 또한 확보할 예정입니다.

진행 중 이슈	Neural Collaborative Filtering 논문을 읽고 공부하면서 저자가 실제 논문 실험에 사용한 NCF 코드를 보게 되었습니다. 저자의 NCF 모델을 분석하면서 저희가 작성한 코드를 개선해야할 필요성을 느꼈습니다. Neural Collaborative Filtering 논문이 발표된지 8년이 지나 맞지않는 환경 버전, 모듈의 차이 등으로 인해 다른 논문, 깃허브에 공유되어 있는 최신 예제와 코드들을 찾아 분석해보며 저희 코드의 미흡한 부분을 개선하고자 합니다.
다음 4주간 계획	Neural CF layer - GMF와 MLP 통합 단계까지 구현 완료 및 개선