

졸업 프로젝트 6월 2차 격주보고서		
SNN을 활용한 고효율 추천 시스템 개발 및 최적화 연구		
2020058259 이승현 2020061676 이강혁		지도교수 김상욱 교수님
지난 2주간 진행사항	Neural CF layer - GMF와 MLP 통합 단계까지 구현 완료 및 개선	△
진행 내용	1. 개선한 점 기존에 작성한 GMF와 MLP 코드에 미흡한 부분이 있다고 생각되어 아래의 부분들을 중심으로 기존의 코드를 수정 및 개선하였습니다. 평가 지표 함수 추천 시스템의 성능 평가를 위한 다양한 평가 지표들을 구현하였습니다. Hit Ratio@K, NDCG@K, Precision@K, Recall@K 등 핵심 평가지표들을 모두 계산할 수 있도록 하였으며, 이를 통해 결과의 정확도 및 사용자 만족도를 종합적으로 평가하여 적합한 parameter을 찾는 등의 성능 향상이나 비교 분석에 활용할 예정입니다. 가중치 초기화 _init_weight 함수를 사용해 nn.Linear와 nn.Embedding 레이어에 대해 각각 self.apply호출로 모델 내 레이어에 대해 초기화 함수를 적용합니다. nn.Linear 레이어는 Xavier Uniform 초기화를 사용하여, 학습 시작 시 가중치가 적절한 범위에 분포되도록 하여 모델이 안정적이고 빠르게 수렴할 수 있게 돕습니다.	

이런 적절한 초기값 설정이 학습의 안정성과 속도를 높이고 최적화 과정에서 좋은 성능을 이끌어 낼 수 있어 이 부분을 개선하였습니다.

2. 개선할 점

코드의 미흡한 부분들을 개선하였지만 성능 지표로 모델을 평가한 결과, 성능이 좋지 못하여 성능 개선을 위한 부분을 찾고 수정하고자 합니다.

정규화 기법

self.mlp layers의 각 레이어 뒤에 dropout을 추가하여, 학습 과정에서 일부 뉴런을 무작위로 비활성화 하는 방식을 적용했습니다. 이러한 정규화 기법은 overfitting 을 방지하는데 효과적이며, 모델이 어느 특징에 지나치게 의존하는 현상을 줄여줍니다. 그 결과, 모델이 더 다양한 특성에 대하여 일반화를 지니는 능력을 갖추게 되고 새로운 데이터에 대한 성능이 향상됩니다.

추가로 batchNorm 와 같은 정규화 기법 또한 학습 안정성과 수렴 속도를 높여주는데, 이를 적용하여 내부 데이터 분포 변화를 완화하여 모델의 성능을 더 향상시킬 계획입니다.

hyper parameter 선정 문제

먼저 선행 연구와 논문에서 추천하는 값들을 참고하여 초기 세팅을 구성 중이며, 이후 성능을 고려하여 최적의 조합을 찾고 있습니다. 특히 중요한 hyper parameter인 layer 수, layer 크기, dropout 비율 등을 중심으로 설정하고 있습니다. 더불어 hyper parameter 최적화 라이브러리도 활용하여 탐색 효율성을 높이고 최적의 값을 도출해 볼 예정입니다.

Zero-Injection 사용

Zero Injection은 MF 이전에 user-item 매트릭스에 "unrated"인 부분에 negative value를 인위적으로 추가하여 모델 학습에 활용하는 기법입니다.

실제 user-item 데이터는 대부분 값이 비어있고, 존재하는 값은 적기에 모델이 학습하는 데에 어려움이 있을뿐더러, MF의 결과로 낮은 rating 값을 가질 확률이 높은 unrated인 부분이 기존의 존재하는 rating 값의 영향을 받아 높은 rating 값으로 채워지는 문제가 있습니다.

Zero-Injection은 이러한 매트릭스의 빈 부분을 0으로 채워 넣음으로써 보다 높은 정확도로 학습할 수 있도록 합니다.

그렇기에 optimizer로 사용하고 있는 Adam 대신 사용하였을 때 높은 성능을 기대할 수 있을 것 같다고 생각하였습니다.

다만, Zero-Injection 또한 unrated item을 무조건 user가 관심없다고 판단하는 것과 0이 실제 rating 값 범위에 포함되지 않기 때문에 전체적으로 rating 값이 작아질 수 있는 문제가 있습니다.

따라서 가능하다면 '0' 대신 사용하였을 때 성능이 가장 높게 나온다고 알려진 '2'를 사용하거나, Users' Preferences 개념을 사용하여 user-item 매트릭스를 정확하게 채우도록 하려고 합니다.

GMF, MLP 학습 분리

embedding 차원, 학습 횟수를 다르게 부여해서 성능의 개선이 있는지 확인할 예정입니다.

논문에서는 GMF와 MLP에 대해서 embedding vector를 따로 생성하여, 두가지 다른 구조에 대해서, 다른 차원의 embedding이 가능하도록 하고 있습니다. 이는 둘을 동시에 랜덤으로 초기화하여 학습하면, 파라미터 공간이 훨씬 커져서

	(1) GMF 쪽이 쉽게 수렴해 버려 MLP가 제대로 학습되지 않거나 (2) MLP의 비선형성에 의해 GMF의 학습 결과 값이 영향을 미치지 못하는 문제가 발생할 수 있기 때문입니다. embedding vector를 따로 생성하여 GMF는 선형 패턴을, MLP는 비선형 패턴을 학습하여 두 결과를 종합할 때 한 쪽이 다른 쪽에 영향을 미치지 않으면서 두 패턴의 특징이 균형 있게 결합되어 좋은 성능을 낼 수 있습니다. Pretrain 적용 Gradient descent 과정에서 optimal 값이 global minimum임을 보장할 수 없습니다. 이를 해결하기 위해서 논문에서는 GMF, MLP를 분리하여 각각 pretrain하고, 그 결과를 통해 parameter를 초기화하여 local minimum에 빠질 확률을 줄이는 방법을 사용했습니다. 또한, hyperparameter를 추가로 사용하여 GMF, MLP의 가중치를 조정하도록 하였습니다. 이를 통해 더 빠른 학습 속도와 평가지표에서의 더 높은 성능을 보여줍니다. => 위의 GMF, MLP 학습 분리와 이를 통한 pretrain을 통해 성능의 개선이 이뤄질 것이라 생각하여 이를 적용할 계획입니다.
진행 중 이슈	
다음 2주간 계획	Hit Ratio@K를 0.7 이상, NDCG@K를 0.45 이상의 성능 향상을 목표로 두고 이를 바탕으로 한 SNN 계획 수립