

졸업 프로젝트 7월 1차 격주보고서		
SNN을 활용한 고효율 추천 시스템 개발 및 최적화 연구		
2020058259 이승현 2020061676 이강혁		지도교수 김상욱 교수님
지난 2주간 진행사항	Hit Ratio@K를 0.7 이상, NDCG@K를 0.45 이상의 성능 향상	△
	SNN 계획 수립	○
진행 내용	1. NCF 모델 구현 1) GMF, MLP 학습 분리 먼저, GMF, MLP 분리하여 학습을 한 뒤 병합하는 과정과 pretraining에서 GMF와 MLP 모델을 초기 학습시키는 과정에서 혼동이 있었습니다. embedding 차원은 분리하되 학습 횟수는 동일하게 1 epoch씩 진행하고 병합하도록 하였습니다. GMF의 embedding 차원(= 8)이 MLP의 embedding 차원(= 32)보다 작게 설정하였고, 이를 통해 약간의 성능을 개선할 수 있었습니다. 논문에서도 GMF와 MLP에 대해서 embedding vector를 따로 생성하여, 다른 차원의 embedding이 가능하도록 하고 있습니다. 이는 한 쪽이 다른 쪽에 비해 빠르게 학습되어 값이 수렴하거나, 차원 크기의 차이로 값이 영향을 미치지 못하게 되는 문제 때문입니다. 또한, GMF와 MLP를 병합할 때 가중치 알파는, 선형적 특징과 비선형적 특징이 균형있게 작용하도록 0.5의 값을 사용하였고, 이 값에서 가장 좋은 성능을 보여주었습니다.	

2) negative sampling

Ranking data를 가져올 때, user-item 매트릭스의 값 중 대부분이 비어 있는 상태입니다. 이를 해결하기 위해 unranked인 값을 사용자가 관심없는 negative data로 볼 수 있지만, 이는 unranked인 부분이 꼭 사용자가 관심없는 부분이라고 할 수 없고, 매트릭스 전체에 대한 계산이 필요하기에 계산량이 크게 증가한다는 문제가 있습니다.

Negative Sampling은 각 positive sample마다 일정 비율(일반적으로 P:N = 1:4)의 negative sample만 랜덤하게 뽑아 처리함으로써 위와 같은 문제를 해결하고, 학습 효율과 속도를 높일 수 있습니다. 또한, 학습의 편향을 막고 overfitting을 완화하는 장점이 있습니다.

논문에서도 negative sampling을 사용하여 학습을 진행하였고, 실제로 이를 적용하여 학습시켜 본 결과 평가 지표의 성능이 2배 가까이 오른 것을 확인할 수 있었습니다.

위의 기법들을 모두 적용한 후 (pretrain을 제외) 목표 평가 지표를 달성하였습니다.

2. 앞으로의 연구 방향성 계획 수립

1) 연구 방향성

저희는 암시적 피드백데이터를 사용하는 SNN-CF 구조를 설계할 생각입니다. 클릭, 조회, 찜, 구매와 같은 행동 이벤트를 시간 축에 따라 spike로 변환하고, 이 시퀀스를 입력으로 받아 사용자-아이템 관계를 학습하는 SNN 구조를 구성함으로써, 명시적 피드백 없이도 작동 가능한 추천 시스템을 구현하는 것이 저희 목표입니다.

2) Neuromorphic Chip 시뮬레이션 서비스 활용 방안

[EBRAINS: Europe's Research Infrastructure for Brain Research - EBRAINS](#)

neuromorphic chip을 개인이 직접 구매할 수 있는 방법이 없어서, neuromorphic chip을 대여, 정확히는 시뮬레이터를 제공하고 그 시뮬레이터를 neuromorphic chip을 사용하여 대신 실행해주는 사이트를 찾았습니다.

이를 이용하기 위해서 연구 중인 주제에 대한 정보를 포함하여 요청을 하고 그 요청을 수락하면 이용할 수 있는 시스템입니다. 그렇기에 SNN을 활용한 추천시스템 구현에 대한 내용을 좀 더 정리하여 요청을 보낼 계획입니다.

또한, 논문에서 주로 사용하는 SNN 라이브러리(NEST, Brian2, SpikingJelly 등)를 사용하여 구현할 예정입니다.

위 사이트는 EU의 후원을 받는 국제 비영리 협회(AISBL)이며, SNN에 관련된 강의 영상이 있어 이를 공부할 생각입니다.

3) 데이터셋 선정

데이터 셋은 alibaba 데이터를 사용할 예정이며 이를 SNN에 맞게 바꾸어 사용할 예정입니다.

(1) AliExpress User Behavior Dataset (Alibaba)

(2) Taobao User Behavior Dataset (Alibaba)

4) 비교 방법 및 코딩 계획

SNN을 사용하여 기존 모델과 비교를 한 논문 몇개 추가로 찾고, 어떻게 기준을 두고 평가하는지, 에너지 효율성은 어떻게 분석하고 비교하는지 공부할 계획입니다.

(1) 딥러닝 기법 기준 선정

1. Negative Sampling (음성 샘플링)

2. 드롭아웃 (Dropout)

3. 가중치 초기화 / 하이퍼파라미터 튜닝

(2) 에너지 효율성 비교

참고한 논문에서는 memory access를 고려한 전력 비교 방식을 제안하고 있습니다. 이는 SNN과 ANN의 비교에서 동일한 이벤트 기반 아키텍처를 가정하고, 하드웨어가 아닌 디지털 환경에서의 비교를 전제로 합니다. 이에 따라 연산량, 메모리 접근 횟수, 메모리 재사용 정도를 사용하여 디지털 환경에서의 전력 효율을 비교하는 것을 목표로 하고 있습니다.

SNN의 한 layer에서 총 에너지(결과값)은 layer에 존재하는 시냅스에 input으로 들어온 모든 spike의 개수와 뉴런에 input으로 들어온 spike를 timestep에 따라 가중하여 계산한 전위 값의 합입니다. 일반적으로 시냅스 연산 에너지가 timestep 업데이트 에너지에 비해 크기 때문에 각 timestep에서의 업데이트 에너지는 시냅스 연산 에너지에 비해 무시할 수 있게 됩니다.

이 경우, 모든 SNN 모델은 유사한 에너지 소비량을 가지며 시냅스 당 평균 spike만이 ANN과 비교하여 에너지 효율성을 결정합니다. 물론, timestep마다 업데이트되는 spike, 상태 변수 등의 값을 저장하기 위해 메모리 접근이 일어나므로 timesteps의 크기가 큰 경우에는 이를 고려하여야 합니다.

	일반적으로 (timesteps= 10)에서 뉴런 업데이트와 관련된 오버헤드를 무시할 수 있고, (timesteps = 500)에서는 중요한 고려 사항이 됩니다. timesteps가 충분히 작은 경우, 각 timestep에서 업데이트되는 SNN 모델의 상대적인 에너지 효율은 ANN과 비교하여 뉴런 개수에 대한 시냅스 개수의 비율, spike sparsity에 따라 달라집니다. 이 비율이 0.5를 넘으면 SNN은 Eyeriss와 같은 효율적인 ANN보다 전력 효율이 떨어집니다. 그러나 비율이 감소함에 따라 SNN의 에너지 효율성은 빠르게 증가합니다. 이를 통해 이론적으로 spike sparsity를 구하여 SNN의 상대적인 전력 효율을 비교할 수 있음을 알 수 있었습니다.
진행 중 이슈	• Pretrain 적용하면 평가 지표가 낮아지는 문제가 발생 Gradient descent 과정에서 optimal 값이 global minimum임을 보장할 수 없습니다. 이를 해결하기 위해서 논문에서는 GMF, MLP를 분리하여 각각 pretrain하고, 그 결과를 통해 NCF 모델에서 parameter를 초기화하는 fine-tuning을 진행하여 local minimum에 빠질 확률을 줄이는 방법을 사용했습니다. GMF와 MLP의 가중치 또한 조정하도록 하였습니다. 이를 통해 더 빠른 학습 속도와 평가지표에서의 더 높은 성능을 보여줄 거라 예상했지만, Pretrain 적용하면 평가 지표가 낮아지는 문제가 발생하여 수정 및 최적화가 필요합니다.
다음 2주간 계획	1. NCF 모델 구현 - 코드 간결화 및 최적화를 통해 HDCG@K 0.75까지 목표, 여러 평가지표 구현 및 작성 - 그 후 dataset을 implicit data로 변경 2. SNN 활용한 추천시스템 구현에 대한 내용을 정리 후, 시뮬레이터를 제공하고 그 시뮬레이터를 neuromorphic chip을 사용하여 대신 실행해주는 사이트에 제출 3. 논문 찾아보며 SNN의 구조 공부 - 활성화 함수, loss, 데이터 인코딩 등 세부적인 부분 자세히 - 전력 비교 적용 방법 공부