

졸업 프로젝트 9월 1차 격주보고서		
SNN을 활용한 고효율 추천 시스템 개발 및 최적화 연구		
2020058259 이승현 2020061676 이강혁		지도교수 김상욱 교수님
지난 2주간 진행사항	- ANN to SNN 변환을 위한 ANN 데이터셋 선행 작업	△
	- SNN 모델 인코딩/디코딩 알고리즘 수정	△
진행 내용	1. ANN to SNN 변환을 위한 ANN 데이터셋 선행 작업 먼저 데이터셋으로는 taobao의 user behavior csv dataset을 사용합니다. (click 과 purchase) Xin, Xin, et al. "Improving Implicit Feedback-Based Recommendation through Multi-Behavior Alignment." *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '23)*, 2023, pp. 932-941. ACM, https://doi.org/10.1145/3539618.3591697. 위 논문에 따르면 cart 와 fav는 양이 상대적으로 적고, noise가 더 많아서 성능 평가 목적에는 적합하지 않다고 판단하여 저희 또한 click을 보조 행동, purchase를 목표 행동으로 사용했습니다. 추가로, 사용자/아이템 ID를 0부터 시작하는 index로 매핑했으며 클릭:0, 구매:1로 변환하여 행렬을 생성하여 행동 라벨화를 진행했습니다. 학습/테스트 데이터는 구매 데이터 기준으로 4:1로 분리하여 진행했고, 클릭 데이터는 동일 사용자에게 대해 함께 사용했습니다. 이를 통해 클릭은 많고 노이즈가 많지만 풍부한 데이터, 구매는 적지만 신뢰도 높은 데이터라는 특징을 활용할 수 있습니다.	

2. ANN to SNN 전처리가 필요한 이유

ANN: 레이어 출력이 연속값(ReLU 등), 바이어스·BN·Dropout·MaxPool 등 다양한 연산 포함

SNN: 시간축 T 스텝 동안 스파이크(0/1)로 누적발화나 막전위로 출력을 근사

위와 같은 차이 때문에 변환하는 처리가 필요합니다. 같은 가중치라도 활성 크기/분포, 음·양수 처리, 임계치, 타임스텝에 따라 SNN 출력이 ANN 점수와 어긋날 수 있어 랭킹(Recall/NDCG) 보존이 깨질 위험이 큼니다.

따라서 레이어별 스케일/임계치 보정, 음수 분해, BN 접기, 바이어정리, T 선택 같은 변환 전처리가 필요합니다.

3. ANN to SNN 전처리 진행 방법

1) ANN 학습(암시적 셋업)

- 손실: BPR 또는 BCE(implicit)
- 활성: ReLU 계열 유지(음수 제거)
- Dropout 제거(추론 시 필요하지 않음), Bias는 남겨두되 변환 시 흡수
- BatchNorm은 미사용 또는 가중치에 folding

2) 변환 전 보정용 Calibration 셋 준비

- 훈련 데이터의 일부를 Calibration용으로 샘플
- 이 셋으로 레이어별 활성 분포를 모읍니다.

3) 레이어별 스케일·임계치(Vth) 설정

- 시간 스텝 T 설정 (작을수록 빠르지만 근사 오차 상승)
- BatchNorm이 있었다면 가중치·바이어스에 folding합니다.
- Bias는 막전위 기준점(or 입력 상수전류)으로 흡수

4) 마지막 계층의 점수 집계

- SNN 출력은 스파이크 카운트 또는 막전위 누적으로 읽습니다.
- ANN 점수 스케일과 다를 수 있으므로 단조변환 보정으로 랭킹 보존 튜닝

5) 시간 스텝 T 선택(성능-지연 트레이드오프)

- 후보 T를 그리드로 돌려, 검증 Recall@20/NDCG@20이 ANN 대비 차이 최소가 되는 T를 선택합니다.

4. 인코딩&디코딩 - 1:1 매핑 방식의 문제점

- **계산 복잡도:** 출력 뉴런이 N개, 이전 계층의 뉴런이 M개라면, 두 계층을 fully-connected로 연결할 경우 $M*N$ 개의 시냅스 연결이 필요합니다. 아이템이 많아질수록 시냅스 연결이 기하급수적으로 늘어납니다.
- **메모리 한계:** 시냅스 정보(가중치, 지연시간 등)가 메모리에 저장되어야 하는데, 이 과정에서 많은 메모리가 사용됩니다. 또한, SpiNNaker 칩은 메모리가 제한적이므로 많은 정보를 저장하는 데에 부적합합니다.

이 문제를 해결하기 위한 방안을 찾아보았습니다.

(1) Two-Tower

사용자와 아이템을 각각 독립적인 저차원의 임베딩 벡터로 표현한 뒤, 마지막에 이 두 벡터의 유사도를 계산하여 선호도를 예측합니다.

- **User Tower:** user를 임의 크기의 뉴런 그룹으로 population을 구성하고, 이를 통해 임베딩 벡터를 생성합니다.
- **Item Tower :** item을 입력받아, user와 동일한 차원의 임베딩 벡터를 생성합니다. 미리 학습된 모델을 사용해 아이템의 임베딩을 저장해 둡니다.

이후 user와 item의 유사도를 통해 랭킹을 계산합니다.

-> 출력 뉴런 수가 아이템 수와 무관하게 고정된 임베딩 차원 수로 결정되므로 뉴런 수를 줄일 수 있습니다.

(2) Candidate Generation & Reranking

Candidate Generation와 Reranking 두 가지 단계로 이루어져 있습니다.

- **Candidate Generation:** 가볍고 빠른 모델을 사용하여, 아이템 중 현재 사용자가 좋아할 만한 후보 아이템을 1차적으로 빠르게 추려냅니다.
- **Reranking:** 추려진 아이템 수를 출력 뉴런의 수로 설정하여 랭킹을 계산합니다.

-> 위 방식과 마찬가지로 출력 뉴런 수가 아이템 수와 무관하게 임의의 고정된 수로 결정되므로 뉴런 수를 줄일 수 있습니다.

위와 같은 방식으로 랭킹을 계산한 뒤, 평가지표를 통해 기존의 NCF와 정확도 비교를 수행할 예정입니다.

5. 은닉 계층(Population) 설정

기존 딥러닝에서는 많은 layer를 통해 추론을 수행합니다. 하지만, SNN 연구에서는 다음과 같은 이유로 layer를 깊게 쌓지 않고 다른 접근 방식을 취하는 경우가 많습니다.

- **시간적 정보 처리 능력:** SNN의 가장 큰 특징은 스파이크의 발화 시간 정보를 활용한다는 것입니다. 이를 통해서, 굳이 많은 layer 없이도 복잡한 시계열 패턴이나 동적 정보를 처리할 수 있는 잠재력을 가집니다.
- **생물학적 모방:** SNN은 기존의 딥러닝보다 좀 더 뇌의 생물학적 특징 모방에 중점을 두고 고안되었습니다. 이는 깊은 순차적 계층 구조보다는, 광범위하고 재귀적인 연결을 가진 복잡한 네트워크 구조를 가집니다. 따라서 SNN 모델도 깊이보다는 연결의 복잡성에 초점을 맞추는 경우가 많습니다.
- **학습의 어려움:** SNN의 스파이크 신호를 많은 layer를 거치며 전파하고 학습시키는 것이 DNN보다 기술적으로 더 어렵고, 효율도 떨어지는 경우가 대부분입니다.

이러한 경향에 따라 SNN 논문에서는 주로 다음과 같은 구조들이 나타납니다.

- **Shallow Networks (0~1개 은닉 계층):** 간단한 패턴 인식, 로봇 제어, 감각 정보 처리 등, SNN 모델을 적용한 대부분의 분야에서 '입력층 - 은닉층 - 출력층'의 3계층 구조가 사용됩니다. 1개의 은닉층만을 사용하는데도 매우 효과적인 것이 입증되었습니다.

	- Reservoir Computing: 고정된 가중치를 가진 거대하고 무작위적인 순환 신경망(reservoir)을 사용합니다. 입력 신호가 reservoir(은닉 계층)를 통과하며 복잡하고 동적인 패턴으로 변환되면, 출력층의 연결 가중치만 학습하여 원하는 결과를 얻습니다. 이때, 은닉 계층은 1개를 사용하지만 내부적으로 매우 복잡한 구조를 가집니다. - 심층 SNN: 최근 들어 활발히 연구되는 분야로, 사전 학습된 DNN을 SNN으로 변환하거나 SNN에 특화된 학습 알고리즘을 사용하여 2개 이상의 은닉 계층을 갖는 모델을 만듭니다. 주로 복잡한 이미지 분류 문제에 적용됩니다. 6. 인코딩 - 데이터의 실시간 처리 SNN의 이벤트 기반 특성은 실시간 처리에 매우 이상적입니다. 그렇기에 SpiNNaker 칩은 실시간으로 데이터를 처리하는 기능을 제공합니다. 하지만 EBRAINS 사이트에서는 로컬 PC와 원격의 SpiNNaker 칩 간에 실시간 네트워크 통신이 불가능하기에 이 기능을 사용하는 것에 제한이 있습니다. 이를 해결하기 위해 스파이크 시간 목록을 미리 생성하여 실시간 상황을 시뮬레이션하는 방법을 찾아보았습니다. (1) 타임 테이블 만들기 - 데이터의 입력 시간을 임의로 설정합니다. (2) 시간 정보 인코딩 - Rate Coding: 신호의 강도를 스파이크의 빈도로 변환합니다. 강한 신호일수록 더 많은 스파이크를, 약한 신호일수록 더 적은 스파이크를 발생시킵니다. 구현이 간단하고, noise에 강하지만, 스파이크를 세어야 하므로 느립니다. - Temporal Coding: 스파이크의 강도를 스파이크의 발화 시기로 변환합니다. 구현이 복잡하지만, 속도가 빠르고 적은 스파이크로 많은 정보를 전달할 수 있습니다.
진행 중 이슈	ANN to SNN 전처리 진행 중 이슈 1. BN/Dropout/MaxPool 불일치 SNN에 동일 연산이 없어 BN folding, Dropout 제거, Max→AvgPool 또는 합리적 근사 사용하는 방법을 고려중입니다.

	2. 시간 정보 활용 모호 Taobao 데이터셋은 세션성 약하다는 단점이 있습니다. 이에 따라 필요 시간 binning(예: 1h) 으로 click→purchase 지연, 신선도 특성 추가 3. 스파이크는 음수 직접표현 불가 입력 데이터가 "클릭 여부 / 구매 여부(0/1)"라면 입력 단계에서 음수 처리는 필요 없지만, ANN→SNN으로 모델 전체를 변환할 때는, 사용자·아이템 임베딩의 내적(dot product) 은 음수가 될 수 있기 때문에 음수 처리를 고려해야 합니다.
다음 2주간 계획	1. ANN to SNN 변환을 위한 ANN 데이터셋 선행 작업 2. SNN 모델 인코딩/디코딩 알고리즘 수정 3. 시연 준비